深度强化学习求解CVRP(仅考虑车辆容量约束的VRP问题)

Javy
工作让人保持理智
关注她

19 人赞同了该文章

赞同 19
分享

参考文献：

Ben Ticha, Hamza & Absi, Nabil & Feillet, Dominique & Quilliot, Alain & Van Woensel, Tom. (2018). A branch-and-price Algorithm for the Vehicle Routing Problem with Time Windows on a road network. Networks. 73. 10.1002/net.21852.

简介：

该文献使用深度强化学习求解考虑车辆容量约束的VRP问题，所谓的深度强化学习是指在强化学习的框架中使用深度学习模型作为估计Value函数的基本形式。本文中使用到的网络结构为Sequence-to-Sequence结构的网络。这种结构的网络由一个卷积层和一个RNN网络构成，分别称为encoder网和deconder网，encoder网将input中所有feature加工成固定规模的中间层，然后decorder网负责将中间层网络解析成output。文中使用的Sequence-to-Sequence网络在encoder阶段还引入了attention机制，具体attetion的细节在后面介绍。

在强化学习中，每个CVRP的求解被划分成T步，定义第 t 步的状态State为 $X_t = \{x_t^1, \dots, x_t^i, \dots x_t^M\}$，其中 $x_t^i = (s^i, d_t^i)$ 是CVRP中每个站点的属性， s^i 为该站点的地理坐标（静态的二维数据）， d_t^i 为站点 i 在第 t 步还剩下的没有被服务的需求（动态变化的一维数据）。每个CVRP的求解需要一个截止条件，若所有站点的 d_t^i 都为0，意味着所有站点的需求都已经送达了。在第 t 步，依据Policy和 X_{t+1} 选择下一步的动作action， y_{t+1} 。从第0步到第 T' 步的所有action会形成一个sequence， $Y = \{y_t, t = 0, \dots, T'\}$ 。在确定 Y 中的每一步 y_t 时，必须要保证 Y 对应的解是可行的（满足容量、每个站点只拜访一次等约束）。

选择动作action的Policy是某个特定的概率分布， $P(Y|X_0) = \prod_{t=0}^{T'} P(y_{t+1}|Y_t, X_t)$ ， $P(y_{t+1}|Y_t, X_t)$ 是通过深度学习的网络计算得到的， $P(y_{t+1}|Y_t, X_t) = softmax(g(h_t, X_t))$ ，其中 g 是仿射函数，输出一个和input长度相关的vector， h_t 是RNN decoder的state总结之前 $y_0, \dots, y_t$ 的信息。在确定 y_{t+1} 之后， 下一步的状态 X_{t+1} 也就能更新了（ $X_{t+1} = f(y_{t+1}, X_t)$ ）。包含attention机制的Sequence-to-Sequence网络的具体结构如图2和3所示，图2是网络的基本结构，左下角为输入向量 $X_t = \{x_t^1, \dots, x_t^M\}$ ，其中 $x_t^i = (s^i, d_t^i)$ 。 X_t 被embeddings层加工后变成了 $\bar{X}_t = \{\bar{x}_t^1, \dots, \bar{x}_t^M\}$ ，其中 $\bar{x}_t^i = (\bar{s}^i, \bar{d}_t^i)$，即为图2中浅橘色的方块，橘色方块右侧的蓝色方块为基于RNN的decoder网络（这里使用RNN的网是由于一系列 Y 的决策是有时序的），最终 $P(y_{t+1}|Y_t, X_t)$ 的值是基于decoder网络的隐藏层（图2中的蓝色方块）和Embeddings层的值得到。

令 $h_t \in R^D$ （D是embedding输出的维度，详情见后面的VRP算法细节）为第 t 步RNN网络隐藏层的值，attention机制会提供一个权值 a_t ，让网络的输出更加聚焦于关键的Embeddings层的某些 $\bar{x}_t^i$ 。 $a_t = a_t(\bar{x}_t^i, h_t) = softmax(u_t)$ ， 其中 $u_t^i = v_a^T tanh(W_a[\bar{x}_t^i; h_t])$ ， ";" 符号代表向量串联， v_a, W_a 是系数矩阵或向量。最终输出的概率函数和 $\sum_{m=1}^{M} a_t^i \bar{x}_t^i$ 相关，此外还需通过通过softmax函数进行标准化，最终得到 $P(y_{t+1}|Y_t, X_t) = softmax(\tilde{u}_t^i)$， $\tilde{u}_t^i = v_c^T tanh(W_c[\bar{x}_t^i; c_t])$ ，其中 v_c, W_c 是系数矩阵或向量，需要通过训练得到。

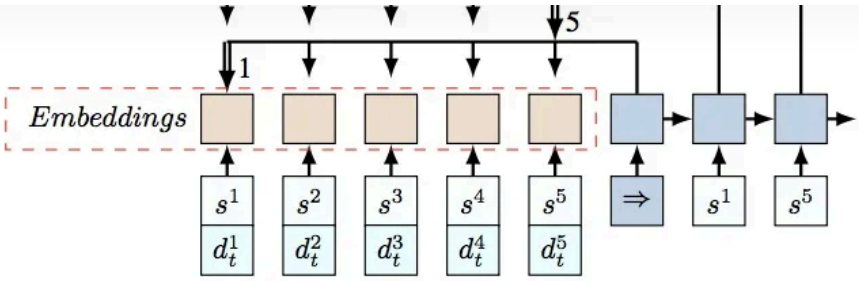


Figure 2. Our proposed model. The embedding layer, on the left, maps the inputs to a high-dimensional vector space. On the right, an RNN decoder stores the information of the decoded sequence. Then, the RNN hidden state and embedded input produce a probability distribution over the next input using the attention mechanism.

知乎 @Javy

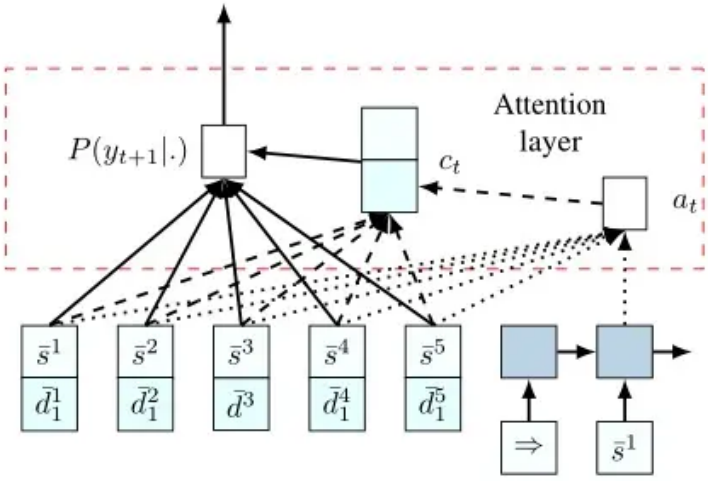


Figure 3. The proposed attention mechanism.

知乎 @Javy

下面介绍强化学习的框架：policy gradient approaches。在框架中使用了两组网络参数，一组是actor network（它的参数为 θ），专门用于计算$P(y_{t+1}|Y_t, X_t)$，用于预测下一步的action；另一组为critic network（它的参数为 ϕ）用于估计每一步执行完action之后 X_t 的reward，critic network的网络结构和上面提到的actor network稍有不同，多了两层（详情需要去看文章）。算法1中iterdation是指强化学习学习的总次数，每一次学习都会包含N个算例（算例是根据某个分布 Φ_M 概率随机生成的），每个算例都会看做一个时序问题，通过若干步求解（算法1第7-11行）。对于整个action向量 Y_t 计算reward，在计算完所有N个算例之后，更新两组网络的参数。

initialize the actor network with random weights θ and critic network with random weights ϕ
for $iteration = 1, 2, \cdots$ **do**
  reset gradients: $d\theta \leftarrow 0, d\phi \leftarrow 0$
  sample N instances according to $\Phi_{\mathcal{M}}$
  for $n = 1, \cdots, N$ **do**
    initialize step counter $t \leftarrow 0$
    repeat
      choose y_{t+1}^n according to the distribution $P(y_{t+1}^n | Y_t^n, X_t^n)$
      observe new state X_{t+1}^n
      $t \leftarrow t + 1$
    until termination condition is satisfied
    compute reward $R^n = R(Y^n, X_0^n)$
  end for
  $d\theta \leftarrow \frac{1}{N} \sum_{n=1}^{N} (R^n - V(X_0^n; \phi)) \nabla_\theta \log P(Y^n | X_0^n)$
  $d\phi \leftarrow \frac{1}{N} \sum_{n=1}^{N} \nabla_\phi (R^n - V(X_0^n; \phi))^2$
  update θ using $d\theta$ and ϕ using $d\phi$.
end for

知乎 @Javy

用该算法求解VRP问题的技术细节：

1、该问题将多vehicle的CVRP看作是one vehicle的CVRP，只是在vehicle自身负载的货物不够时，需要返回depot点，由于这篇文章中不考虑站点的时间窗属性，所以这种简化策略得到的解，就可以简单地视为多vehicleCVRP问题的解。

2、构造算例的时候，站点和depot的地理位置是从 $[0, 1] \times [0, 1]$ 的范围内随机选，每个站点的demand是从离散整数集合 $\{1, \ldots, 9\}$ 中随机选择的。

3、假设vehicle在第0步的时候位于depot点，$X_t = \{x_t^1, \ldots, x_t^M\}$中第一个元素永远是depot点，在每一步decoding时，y_t 的值是从所有站点和depot点中选择，在 $y_t = i$ （车辆拜访完第 i 个站点之后），该站点的demand和车辆的载货量都需要更新：

$$d_{t+1}^i = max(0, d_t^i - l_t),$$
$$d_{t+1}^k = d_t^k, \text{ for } k \neq i,$$
$$l_{t+1} = max(0, l_t - d_t^i),$$

4、在利用decoder网络输出的概率分布选择action时，有两种策略：（1）贪婪策略，每次都选概率最大的站点/depot；（2）beam search策略，同时看好几个概率高的站点，然后选reward最大的那个。然而数值实验证明这两种策略没啥大差别，不挑也罢。在选择action的过程中会用masking scheme 屏蔽不可行的站点，不让action选择。

5、在decoder阶段用的是LSTM的网络结构，隐藏层的state size是128；encoder阶段网络是一层的卷积网，网络的输入数据长度为state X_t 的长度，每个输入数据的维度为 x_t^i 中包含数据的个数，将其mapping到128维的向量中去（前文的D=128）。x_t^i中的动态变量不仅包含之前提到的d_t^i，为站点 i 在第 t 步还剩下的没有被服务的需求（动态变化的一维数据），而且包括在第 t 步服务完站点 i之后车辆还剩余的负载 $l_t - d_t^i$。

6、网络结构的其它特点：Adam优化算子、为防止过拟合，使用0.1的dropout概率和entropy regula

7、训练的时间成本：20个站点的VRP训练100次需要35秒；20个epoch需要13.5小时

Table 3. Average total tour length over a test set of size 1000. Standard deviations are in parentheses.

Task	Vehicle Capacity	Our Framework			Clarke-Wright			Sweep		
		Greedy	BS(3)	BS(10)	Greedy	Rnd(5,5)	Rnd(10,10)	Basic	Rnd(5)	Rnd(10)
VRP10	20	4.80 (0.83)	4.72 (0.80)	**4.65** (0.79)	5.06 (0.85)	4.86 (0.82)	4.80 (0.82)	5.42 (0.95)	5.07 (0.87)	5.00 (0.87)
VRP20	30	6.51 (0.84)	6.45 (0.85)	**6.34** (0.80)	7.22 (0.90)	6.89 (0.84)	6.81 (0.82)	7.59 (0.93)	7.17 (0.85)	7.08 (0.84)
VRP50	40	11.32 (1.27)	11.21 (1.30)	**11.08** (1.27)	12.85 (1.33)	12.35 (1.27)	12.25 (1.25)	13.61 (1.23)	13.09 (1.12)	12.96 (1.12)
VRP100	50	17.12 (1.90)	17.00 (1.88)	**16.86** (1.87)	19.72 (1.92)	19.09 (1.85)	18.96 (1.85)	21.01 (1.51)	20.47 (1.41)	20.33 (1.39)

Table 4. Solution times (in seconds).

Task	Vehicle Capacity	Our Framework			Clarke-Wright			Sweep		
		Greedy	BS(3)	BS(10)	Greedy	Rnd(5,5)	Rnd(10,10)	Basic	Rnd(5)	Rnd(10)
VRP10	20	0.059	0.073	0.074	0.002	0.016	0.079	0.001	0.004	0.008
VRP20	30	0.107	0.147	0.155	0.011	0.053	0.256	0.006	0.029	0.062
VRP50	40	0.176	0.244	0.250	0.052	0.217	0.903	0.096	0.472	0.988
VRP100	50	0.290	0.413	0.477	0.186	0.735	3.171	1.341	6.32	12.443

知乎 @Davy

8、数值实验结果如上图表3所示。

9、文中提到理论上将该算法迁移到VRPTW是可行的，只要在选action的时候把不可行的解用masking scheme挡住就行，但是实际上设计这样的scheme很难。

10、文章中将该算法迁移到stochastic VRP（站点的需求是不确定的），将原来的VRP问题划分为离散时间的MDP问题，需要在100个时间单位的范围内尽可能多地服务更多的站点需求，每个站点会在某个随机的时刻ask一个需求，如果5个时间单位没有得到响应，就取消呼叫。如果在某个时间单位中某个站点出现新需求，或者车辆到达了某个站点，才需要做新的决策。 这里使用的网络和它的基本参数都和前文提到的一致，仅有两处区别：第一处是在action选择的地方使用了不同的策略：actor-critic（A3C）with one-step reward accumulation；第二处是在保证action的可行性方面，每次仅将avaiable的站点和depot和vehicle当前所在的站点组成 $\boldsymbol{X_t}$ 输入网络进行概率的计算，$\boldsymbol{X_t}$ 中的动态变量还包括站点ask需求的时刻，这个量可以帮助网络训练要不要放弃该站点（因为超过5个时间单位不应答就消失了），文章里尝试了好几种reward，大家可以捡自己需要的用。

发布于 2021-07-29 12:00

强化学习 (Reinforcement Learning)　VRP

欢迎参与讨论

5 条评论　默认　最新

没有用户名
您好 ， 关于这篇文章的代码 我有一些问题 ， 期待可以得到您的解答。这篇文章的代码没有地方输入具体问题的客户节点的左边和需求 请问您有什么想法吗?
2022-07-15　回复　喜欢

王晨希
请问您弄清楚您的问题了吗
03-11　回复　喜欢

suzy狐
请问代码的连接是在哪里呢
2022-08-11　回复　喜欢

Javy 作者

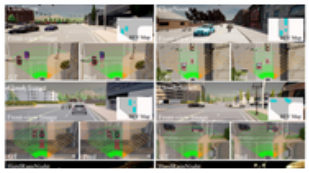
啊 我搞错了 sorry，我去找了那篇文献是：Nazari, M., Oroojlooy, A., Snyder, L. V., & Takác, M. (1802). Deep reinforcement learning for solving the vehicle routing problem. CoRR, abs.，链接是researchgate.net/profil...，我看的时候应该是未发表的版本，发表后的正式文章是Nazari, M., Oroojlooy, A., Snyder, L., & Takác, M. (2018). Reinforcement learning for solving the vehicle routing problem. Advances in neural information processing systems, 31.

2022-02-16 回复 喜欢

文章被以下专栏收录

VRP问题及其变种
求解各种VRP问题的算法

推荐阅读



港理工最新！一种新颖的轻量级BEV感知方法，实现可解释的...

3D视觉工... 发表于3DCVe...

谈谈凌渡ACC功能

车型：2019款 大众凌渡 280舒适 改装初衷： 1.什么是ACC自适应巡航？ ACC自适应巡航又称主动巡航，是一种智能自动控制系统，包括雷达传感器、数字信号处理器和控制模块。驾驶员设定期望的车...

Yan



一文读懂什么是ACC, ACC S&G, iACC, TJA, ICA

锋兄

聊一聊E-CVT（THSII）

E-CVT是CVT吗？从变速器角度分析，它既是恒功率传动，又是连续可变速比，没有理由不称呼它为E-CVT。但是从CVT角度分析，在速比大工况时，扭矩理应大（几倍的速比就该有几倍的扭矩），E-CV

IND4汽车人